PRÁCTICA 2

Contexto y objetivo

En esta práctica trabajaremos con un conjunto de datos procedente de un sistema de sensores químicos electrónicos (*electronic nose*) diseñado para la detección y clasificación de diferentes gases mediante un array de sensores semiconductores.

Uno de los principales problemas asociados a este tipo de dispositivos es la denominada **deriva temporal de sensores** (*sensor drift*), producida por factores como:

- envejecimiento de los sensores,
- variaciones ambientales,
- cambios de calibración,
- degradación física del hardware.

Como consecuencia, la distribución estadística de los datos cambia progresivamente a lo largo del tiempo, dificultando la capacidad de generalización de los modelos de aprendizaje automático.

El objetivo de la práctica será diseñar un sistema robusto de clasificación capaz de identificar correctamente el tipo de gas presente minimizando el impacto de dicha deriva temporal.

El problema se formula como una tarea de clasificación multiclase.

Adquisición de datos

El conjunto de datos contiene medidas obtenidas mediante un array de 16 sensores químicos MOX (Metal Oxide Sensors). Este tipo de sensores modifica su resistencia eléctrica en presencia de diferentes sustancias gaseosas, permitiendo caracterizar químicamente el entorno a partir de la respuesta conjunta del conjunto de sensores.

Cada medición corresponde a la exposición del array de sensores a una determinada sustancia gaseosa bajo unas condiciones concretas de concentración. Durante cada experimento se registra la evolución temporal de la resistencia eléctrica de cada sensor, obteniéndose así una serie temporal de 16 canales.

A partir de dichas señales temporales se han extraído características numéricas que resumen tanto la intensidad de la respuesta como su comportamiento dinámico. En particular, para cada uno de los 16 sensores se calculan 8 características distintas:

- Variación máxima de resistencia respecto al valor basal.
- Variación normalizada de la resistencia.
- Características dinámicas obtenidas mediante medias móviles exponenciales (Exponential Moving Average, EMA) sobre la fase de crecimiento de la respuesta del sensor.
- Características dinámicas equivalentes sobre la fase de decaimiento de la respuesta.

Preprocesado y extracción de características

A partir de las señales temporales registradas por cada uno de los sensores químicos se han extraído un conjunto de características numéricas que resumen tanto la intensidad de la respuesta como su comportamiento dinámico frente a los distintos gases.

Para cada uno de los 16 sensores se calculan 8 características diferentes:

- Variación máxima de resistencia respecto al valor basal (DR).
- Variación normalizada de la resistencia ($|DR|$).
- Características dinámicas obtenidas mediante medias móviles exponenciales (*Exponential Moving Average*, EMA) sobre la fase de crecimiento de la respuesta del sensor (*increasing transient*).
- Características dinámicas equivalentes sobre la fase de decaimiento de la respuesta (*decaying transient*).

Las características dinámicas se calculan utilizando distintos parámetros de suavizado:

$[\alpha = 0.1, 0.01, 0.001]$

con el objetivo de capturar tanto cambios rápidos como cambios lentos en la respuesta temporal de los sensores.

De este modo, cada ejemplo del conjunto de datos queda representado mediante un vector de 128 variables numéricas:

$$16\ sensores \times 8\ características = 128\ variables$$

Las variables aparecen organizadas consecutivamente por sensor siguiendo la estructura:

$$[DR_1, |DR|_1, EMAi_{0.001_1}, EMAi_{0.01_1}, EMAi_{0.1_1}, EMAd_{0.001_1}, EMAd_{0.01_1}, EMAd_{0.1_1},$$

$$DR_2, |DR|_2, EMAi_{0.001_2}, EMAi_{0.01_2}, EMAi_{0.1_2}, EMAd_{0.001_2}, EMAd_{0.01_2}, EMAd_{0.1_2},$$

$$\ldots,$$

$$DR_{16}, |DR|_{16}, EMAi_{0.001_16}, EMAi_{0.01_16}, EMAi_{0.1_16}, EMAd_{0.001_16}, EMAd_{0.01_16}, EMAd_{0.1_16}]$$

donde:

- (DR_j) representa la variación máxima de resistencia del sensor (j),
- ($\lceil DR \rceil_j$) corresponde a su versión normalizada,
- (EMA_i) representa características de crecimiento (*increasing transient*),
- (EMA_d) representa características de decaimiento (*decaying transient*).

Los datos se encuentran organizados en distintos ficheros correspondientes a *batches* temporales diferentes. Cada *batch* agrupa mediciones realizadas en distintos periodos de adquisición distribuidos a lo largo de varios meses, permitiendo estudiar el efecto de la deriva temporal de los sensores.

Adicionalmente, los datos suministrados en esta práctica se encuentran divididos en distintos bloques temporales asociados a diferentes rangos de meses de adquisición.

Dentro de cada fichero, cada línea representa una medición individual codificada en un formato similar al utilizado por LIBSVM:

$$[(x): (v)]$$

donde:

- (x) representa el identificador de la variable,
- (v) representa el valor numérico asociado.

Por ejemplo:

$$[1: 10.000000,\ 1: 15596.162100,\ 2: 1.868245,\ \ldots]$$

indica:

- clase 1 (Ethanol),
- concentración de 10 ppmv,
- seguido de los valores de las 128 características extraídas del array de sensores.

Las clases del problema corresponden a los siguientes gases:

1. Ethanol
2. Ethylene
3. Ammonia
4. Acetaldehyde
5. Acetone
6. Toluene

Organización del conjunto de datos y valores perdidos

El conjunto de datos final está compuesto por variables numéricas derivadas de la respuesta dinámica de los sensores químicos frente a distintos compuestos gaseosos.

Las variables incluyen:

- respuestas máximas y mínimas,
- características asociadas a la velocidad de respuesta,
- relaciones entre sensores,
- descriptores estadísticos,
- características derivadas de la dinámica temporal de las señales.

Durante el proceso de adquisición experimental pueden producirse incidencias asociadas al funcionamiento de los sensores, incluyendo:

- fallos temporales de lectura,
- registros incompletos,
- interferencias eléctricas,
- ruido excesivo,

- necesidad de sustitución o limpieza de sensores.

Es por ello que algunos datos de cada uno de los *batches* pueden faltar o no estar presentes, por ello, se recomienda:

- analizar la distribución de los valores perdidos,
- estudiar su posible patrón de aparición,
- y justificar razonadamente el mecanismo de ausencia de datos más probable.

En particular, se recomienda discutir si el comportamiento observado resulta más compatible con:

- MCAR (Missing Completely At Random),
- MAR (Missing At Random),
- MNAR (Missing Not At Random),

así como las posibles implicaciones de dicha hipótesis sobre las estrategias de imputación y el posterior entrenamiento de los modelos.

Organización del conjunto de datos

Los datos se distribuyen en múltiples ficheros correspondientes a diferentes batches temporales.

Cada ejemplo contiene:

- variables numéricas continuas de los sensores
- identificador del batch temporal,
- clase de gas asociada.

Atributos

El conjunto de datos está formado por:

- **Identificador del batch:** indica el periodo temporal de adquisición al que pertenece la muestra.
- **Características sensoriales:** variables continuas derivadas de las respuestas de los sensores químicos.
- **Etiqueta de clase:** tipo de gas correspondiente a la muestra.

Número de ejemplos	13910
Número de variables	129
Tipos de datos	Reales y Categóricos
Enlace para la descarga	Datos

Entrega

Para la evaluación de esta práctica deberán entregarse dos elementos fundamentales, que serán revisados conjuntamente:

1. Notebook o fichero ejecutable

Se deberá entregar un archivo en formato:

- Jupyter Notebook (`.ipynb`)
- script en Julia (`.jl`)

que pueda ejecutarse completamente de principio a fin sin errores y de forma reproducible.

El fichero deberá incluir todas las fases desarrolladas durante la práctica, incluyendo al menos:

1. carga y preparación de los datos,
2. análisis exploratorio,
3. tratamiento de valores perdidos,
4. construcción de pipelines,
5. entrenamiento y evaluación de modelos,
6. validación experimental,
7. visualización de resultados,
8. análisis comparativo,
9. conclusiones parciales.

Se valorará especialmente que el código presente una estructura clara y organizada, con una adecuada modularidad y reutilización de componentes. Asimismo, se tendrá en cuenta la claridad y legibilidad de la implementación, el uso apropiado de comentarios explicativos y la correcta separación entre los conjuntos de entrenamiento, validación y test. También se considerará fundamental la reproducibilidad experimental y la capacidad del notebook o script para ejecutarse de forma autónoma sin requerir modificaciones adicionales.

El notebook o script deberá poder ejecutarse sin modificaciones adicionales y generar automáticamente todos los resultados incluidos en la memoria.

Importante: en caso de que no se pueda ejecutar o que alguna de las configuraciones tenga que modificarse el código o pasar parámetros, la práctica se considerará como invalida y no se corregirá.

2.Memoria del trabajo

Se deberá entregar una memoria en formato PDF donde se describa el trabajo realizado y se analicen los resultados obtenidos.

La memoria deberá incluir, al menos las siguientes secciones indicadas en la sección de valoración de la memoria.

Además de presentar los resultados, la memoria deberá justificar razonadamente las decisiones metodológicas tomadas durante el desarrollo de la práctica.

Se valorará especialmente la claridad expositiva y la coherencia global del documento, así como el rigor metodológico empleado en el diseño experimental y en el análisis de resultados. También se tendrá en cuenta la capacidad crítica en la interpretación de los experimentos realizados, la calidad de las representaciones y comparativas incluidas, y el uso de una redacción técnica y académica adecuada.

Trabajo a realizar

Uno de los elementos fundamentales de esta práctica es la presencia de:

- deriva temporal,
- cambios distribucionales entre *batches*,
- valores ausentes.

Por tanto, deberá prestarse especial atención tanto al diseño experimental como a la correcta validación de los modelos y a la interpretación crítica de los resultados obtenidos.

Preparación de los datos (10 % de la calificación)

La primera parte del trabajo incluirá toda la parte de trabajo con los datos

1. Carga y unificación de datos

Los datos se encuentran distribuidos en varios ficheros correspondientes a distintos batches temporales.

Se pide:

1. crear un único *dataset* consolidado,
2. incorporar adecuadamente la información temporal asociada a cada *batch*,
3. realizar una descripción básica del conjunto de datos incluyendo:
    a. número de variables,
    b. número de instancias,
    c. número de *batches*,
    d. número de clases.

2. Análisis de valores ausentes

Calcule:

- el porcentaje de valores nulos por variable,
- el porcentaje global de valores ausentes del conjunto de datos.

Analice, además:

- posibles patrones de ausencia,
- distribución de los valores perdidos entre *batches*,
- posible impacto sobre el modelado y la validación.

Asimismo, deberá discutirse razonadamente qué mecanismo de ausencia de datos parece más compatible con el comportamiento observado:

- MCAR (Missing Completely At Random),
- MAR (Missing At Random),
- MNAR (Missing Not At Random).

3. Tratamiento y transformación de datos

Realice las transformaciones necesarias para el uso de algoritmos de clasificación. Se deberá:

- imputar valores faltantes cuando sea posible,
- justificar cualquier variable descartada,
- documentar todas las decisiones de *preprocessing*,
- evitar posibles situaciones de *data leakage* durante las fases de transformación.

4. Partición holdout temporal

Reserve los *batches* temporales más recientes como conjunto de test final.

Condiciones:

- el conjunto de test debe representar aproximadamente el 10 % de las instancias,
- utilice la semilla 104 cuando sea necesario,
- liste explícitamente los *batches* utilizados para entrenamiento y test.

La separación deberá respetar el orden temporal de adquisición de los datos.

5. Validación cruzada *batch-wise*

Con los batches restantes:

- cree una validación cruzada 5-Fold respetando la estructura temporal,
- asegúrese de que muestras pertenecientes al mismo *batch* no aparezcan simultáneamente en entrenamiento y validación.

Puntos que afectaran a la calificación:

- validación aleatoria convencional,
- mezcla de muestras entre *batches*,
- uso de información procedente del conjunto de test durante el entrenamiento o *preprocessing*.
-

6. Normalización o estandarización

Aplique:

- Min–Max scaling

o justifique adecuadamente el uso de otro método de normalización.

Las transformaciones deberán:

- ajustarse únicamente sobre entrenamiento,
- aplicarse posteriormente sobre validación y test.

Modelos básicos y selección de atributos (30 %)

Una vez completada la fase de preparación y validación de los datos, se procederá al entrenamiento y comparación de distintos modelos de aprendizaje automático. En esta parte de la práctica se estudiará tanto el efecto de distintas estrategias de selección y reducción de características como el comportamiento de diversos clasificadores base y modelos ensemble frente al problema de deriva temporal presente en el conjunto de datos.

1. Filtrado de características

Aplique las siguientes variantes:

- Sin reducción
- Filtrado ANOVA
- Filtrado de Pearson
- Filtrado de Spearman
- Filtrado de Kendall Tau
- Filtrado por *Mutual Information*
- Filtrado RFE (con *Logistic Regression*, eliminando el 50 % de las variables en cada iteración)

2. Reducción por proyección

Para cada filtrado, aplique al menos una de las siguientes técnicas:

- Sin reducción adicional
- PCA
- LDA
- ICA

3. Entrenamiento de clasificadores base

Entrene los siguientes modelos sobre los conjuntos resultantes:

- MLP: arquitecturas [50], [100] y [100, 50]
- KNN: valores de k = 1, 10 y 20
- SVM: parámetro C = 0.1, 0.5 y 1.0

No es necesario evaluar todas las combinaciones posibles, pero sí que todas las técnicas aparezcan al menos una vez en alguno de los experimentos realizados. Por ejemplo, haciendo un modelo que haga el filtrado ANOVA, con PCA y haga un MLP de 50, ya no sería necesario volver a repetirlos en otro.

Modelos de *ensemble* (20 %)

En esta segunda parte del trabajo se estudiará el comportamiento de distintas estrategias de aprendizaje ensemble sobre un problema con deriva temporal y cambios distribucionales entre *batches*. Se pretende analizar hasta qué punto la combinación de

múltiples clasificadores puede mejorar la robustez y capacidad de generalización de los modelos frente a escenarios más realistas y menos estacionarios.

1. Ensembles sobre datos con PCA (95 %) o sin reducción

Entrene los siguientes modelos:

- **BaggingClassifier:** clasificador base *KNN (k = 5)*, con 10 y 50 estimadores
- **AdaBoost:** estimadores *Stump Trees*, con 5 clasificadores base
- **EvoTree (EvoTree):** 50 100 estimadores, *learning_rate* = 0.2

2. Evaluación final sobre el conjunto de test (10 % holdout)

Entrene los modelos anteriores usando **todo el conjunto de entrenamiento (5-Fold completo)**.

- Seleccione las **cinco mejores combinaciones** obtenidas (una de cada tipo: KNN, SVM, MLP, Bagging, AdaBoost).
- A partir de ellas, construya los siguientes modelos compuestos:
    - **Random Forest:** 500 árboles, profundidad máxima 10
    - **Hard Voting:** con SVM como modelo base, particione en 3 el conjunto de entrenamiento con el valor 104 y ejecute la votación por mayoría
    - **Stacking Ensemble:** MLP como clasificador final; base SVM + KNN + MLP
    - **XGBoost**, **LightGBM** y **CatBoost** (valores por defecto)

Visualización de los datos (10% de la calificación)

Genere representaciones bidimensionales de los datos mediante las siguientes técnicas:

- PCA
- LDA
- ICA
- t-SNE
- Isomap
- LLE

En caso necesario, implemente *wrappers* o *pipelines* adecuados. Las transformaciones deberán ajustarse con los datos de entrenamiento y aplicarse después sobre los datos de test para la visualización.

Significación de las variables (5% de la calificación)

Analice la importancia de variables utilizando:

- Random Forest
- XGBoost

Discuta:

- variables más relevantes,

- estabilidad de importancia entre *batches*,
- posibles efectos de *drift* temporal.

Evaluación experimental y discusión metodológica (5% de la calificación)

Además de las métricas habituales, deberá incluirse una discusión crítica sobre:

- impacto de la deriva temporal,
- diferencias entre validación correcta e incorrecta,
- riesgos de *data leakage*,
- capacidad real de generalización,
- estabilidad de los modelos frente a cambios distribucionales.

Presentación y memoria (20% de la calificación)

La evaluación de la memoria y la entrega considerará tres aspectos principales:

Presentación del código y notebook

Se valorará especialmente:

- ejecución completa y reproducible,
- claridad y organización del código,
- modularidad y reutilización de componentes,
- documentación y comentarios explicativos,
- uso correcto de *pipelines* y separación experimental.

Organización de la memoria

La memoria deberá incluir:

1. Introducción y descripción del *dataset*
2. Análisis exploratorio inicial
3. Tratamiento y análisis de valores perdidos
4. Estrategias de *preprocessing* aplicadas
5. Descripción del pipeline experimental
6. Resultados experimentales
7. Comparativa de modelos
8. Análisis del *drift* temporal
9. Discusión metodológica
10. Conclusiones finales
11. Test estadístico sobre resultados de validación cruzada

No será necesario aplicar el test estadístico sobre el conjunto final de test, dado que únicamente se dispondrá de una única evaluación holdout final.

Claridad y coherencia

Se valorará especialmente:

- rigor científico,

- capacidad crítica,
- justificación metodológica,
- interpretación de resultados,
- reproducibilidad experimental.